

Лабораторная работа № 7

Семантический анализ текста.

На основе этого задания можно сделать UI-приложение для семантического анализа введенного пользователем текста, это по желанию.

1. Подготовьте текст объемом 4–6 предложений на русском языке или англ. (новость, отрывок из статьи), в тексте должны встречаться географические названия/имена людей/названия компаний/физические обозначения/денежные единицы.
2. Импортируйте библиотеку Spacy и загрузите модель для русского или английского языков, зависит от языка выбранного текста.
3. Создайте объект Doc и убедитесь, что модель корректно обработала текст (проверьте `len(doc)`, `doc.sents`).
4. Разбейте текст на токены, выведите первые токены, их леммы, часть речи, принадлежность к стоп-словам. Отфильтруйте стоп-слова, пунктуацию и числа.
5. Выведите список всех лемм. Поясните, как лемматизация и фильтрация влияют на качество последующего семантического анализа.
6. Определите именованные сущности, выведите все географические названия, или имена собственные, или названия организаций.
7. * Для одного любого предложения определите типы зависимостей, постройте дерево зависимостей (по желанию).

Облако слов

1. В качестве обрабатываемого текста можно взять то, что вам интересно, например, историю беседы в телеграме, интервью с кумиром, тексты песен и т.д. Текст должен подгружаться из файла.
2. Текст необходимо обработать: убрать знаки препинания, стоп-слова (это предлоги, союзы, можно в список стоп-слов добавить свои слова), привести слова к начальной форме.
3. Придайте облаку слов контуры какой-либо фигуры, на ваш выбор.
4. Объяснить какие библиотеки на каком этапе работы использовались.

* Для тех кому интересно. Работа с эмбендингами слов.

Эмбендинги – это методы векторизации слов с использованием нейросетей. В отличие от рассмотренных в прошлой работе простых методов векторизации слов, эмбендинги рассматривают контекст слова, это позволяет учитывать семантику слов и, таким образом, удобно для поиска семантически близких слов и текстов. Принцип эмбендингов используется во внутренних механизмах современных LLM.

Существует множество моделей текстовых эмбендингов. Ваша задача поработать минимум с двумя моделями и сравнить эффективность их работы на одинаковых задачах.

1. Загрузите предобученные эмбендинги, например, Word2Vec от Google News, GloVe от Stanford), FastText от Facebook или иные.
2. С использованием библиотеки gensim реализуйте скрипт, который:
 - ищет семантически схожие слова (синонимы) для какого-либо заданного слова;
 - выполняет аналогию типа "Париж – Эйфелева башня, Минск - ?" или "Италия – пицца, Германия - ?" или др.