

Лабораторная 6. Работа с данными (4 часа)

Изучим:

- методы парсинга данных с сайтов (библиотеки Requests, BeautifulSoup, Selenium),
- статистическую обработку полученных данных (библиотеки NumPy и Pandas),
- визуализацию данных (библиотеки Matplotlib и Seaborn).

1. Выберите сайт с которого можно спарсить информацию примерно следующего вида:

- название товара – цена *или*
- марка машины – объем двигателя *или*
- дата – обменный курс доллара *или*
- *лучше парсить несколько значений, например, **товар-цена-рейтинг** и т.д., в этом случае можно получить более интересные результаты при последующем анализе.*

для парсинга статических страниц можно использовать библиотеки **Requests**, **Beautiful Soup**, а для парсинга динамических страниц – **Selenium**. Например, используя **Selenium**, можно ввести поисковый запрос и спарсить результаты поиска.

2. Сохраните данные в csv-файл.

3. В новом модуле прочитайте данные из csv-файла. Для работы с данными импортируйте библиотеки **NumPy** и **Pandas**.

- 1) Выведите 5 первых значений.
- 2) Добавьте новый столбик, который будет результатом какого-либо расчета, например, если есть столбик Цена, то можно добавить новый столбик Цена с учетом скидки, в котором значения из Цена будут умножаться на процент скидки.
- 3) Добавьте еще один столбец со сгенерированными значениями, например, Рейтинг.
- 4) Выведите 10 первых значений.
- 5) Примените метод *describe* для расчета основных метрик статистики, объясните полученные результаты.
- 6) Если данные в первом столбике повторяются, то примените группировку (например, выведите среднюю цену повторяющегося товара).

4. Визуализируйте распределение данных при помощи библиотек **Matplotlib** или **Seaborn**.

- ✓ Постройте гистограмму, подпишите оси. Объясните, что показывает диаграмма.
- ✓ Постройте диаграмму box-plot. Объясните, что изображено на этой диаграмме.
- ✓ Можно построить еще какие-либо диаграммы, доступные в этих библиотеках.

5. Создайте файл с анализом данных из файла *Vegetabls_sales.csv* (на diskstation) (см. п.6):

- ✓ Сгруппируйте данные по названиям продуктов (сколько всего продано каждого наименования)
- ✓ Сгруппируйте данные по названиям продуктов и по городу (сколько продано каждого продукта в каждом из городов)
- ✓ Найдите три самых продаваемых продукта.
- ✓ Постройте диаграммы по сгруппированным данным.

6. * Вместо файла *Vegetabls_sales.csv* можно использовать для анализа данные, которые представляют для вас личный интерес, например, статистика по героям компьютерной игры, статистика по зарплатам специалистов или по налогообложению в разных странах. Датасеты в этом случае необходимо найти самостоятельно.